Arbitraje estadístico multiactivo con cointegración y filtros de Kalman

Lab03 · Microestructuras y Sistemas de Trading · ITESO — Equipo 6: Gonzalo Cano y Juan Manuel Espinosa · noviembre de 2026

Fuente de cada cifra: `artifacts/` (lo genera `python main.py`) y `docs/decisiones.md`. Alcance: Lab03 completo sin la sección 3.7 (Risk Parity), por indicación del profesor.

Resumen ejecutivo

- **Grupo:** la tercia **GLD-GDX-B** (ETF de oro, ETF de mineras de oro y Barrick), cointegrada en entrenamiento (traza 35.8 contra 29.8 al 95 %, rango 1, vida media del spread 29 días).
- **Modelo:** Johansen da el vector inicial; el **filtro de Kalman 1** deja que los pesos deriven despacio; el **filtro de Kalman 2** convierte el término de corrección de error (ECT) en un z-score con estadísticos *prior*; una regla de bandas con stop y holding máximo decide la dirección; el backtest cobra comisión por pata y préstamo de cortos.
- **Resultado (θ congelado desde train, walk-forward):** Sharpe neto **0.66 / 0.74 / 1.01** en entrenamiento / prueba / validación, rendimiento +20.5 % / +8.1 % / +11.2 %, drawdown máximo –6.6 % / –4.5 % / –3.7 %. Total encadenado 2013–2026: +44.8 %, Sharpe 0.75. Los costos se llevan 21–25 % del P&L bruto.
- **Lectura honesta:** la relación **se debilita sin romperse** fuera de muestra y el filtro 1 absorbe la deriva. El grupo se eligió en una segunda iteración, después de que el primero (GLD-GDX-AEM-FNV) perdiera la cointegración en validación; corrigiendo por los 19 grupos candidatos, el Sharpe deja de ser estadísticamente concluyente (Sharpe deflactado ≈ 0.46). La relación tiene fundamento económico, pero la evidencia de que sea explotable es moderada.

1. Universo, justificación económica y pruebas múltiples

Datos. Precios ajustados diarios de Yahoo Finance del 2012-01-03 al 2026-10-30 (≈ 14.8 años), guardados en un snapshot versionado (`data/snapshot/`) para que la corrida no dependa de la descarga. Partición 60/20/20 por fecha, calculada una vez y congelada: **entrenamiento** 2012-01-03 → 2020-11-19, **prueba** 2020-11-20 → 2023-11-08, **validación** 2023-11-09 → 2026-10-30. Forward-fill de máximo 3 días y nunca back-fill.

Universos con justificación económica (criterio fijado antes de correr).

- *Iteración 1:* petroleras de EE. UU. y Europa (126 cuartetos) y oro + mineras (70 cuartetos), grupos de 4 = 2 × integrantes. Resultado: GLD-GDX-AEM-FNV.
- *Iteración 2 (autorizada por el profesor):* solo oro + mineras (GLD, GDX, NEM, AEM, KGC, B, AU, FNV), con pares, tercias y cuartetos: 154 grupos. Resultado: **GLD-GDX-B**. El metal, el ETF de mineras y una de sus posiciones más grandes comparten la tendencia casi de forma mecánica: las mineras son una opción apalancada sobre el precio del oro y GDX es una canasta de ellas. AEM y FNV (regalías) tienen dinámicas propias que pueden separarse del oro por años.

Pruebas múltiples. En total se probaron **280 grupos distintos**. En la iteración 2, Johansen rechaza r = 0 al 95 % en 30 de 154 grupos cuando por azar se esperarían 7.7; solo 4 rechazan al 99 % y la corrección de Bonferroni exigiría α = 0.00032. Por eso el embudo no se queda en Johansen: exige correlación, un vector con ADF significativo y una vida media operable, y el reporte declara el sesgo de selección (sección 9).

2. Embudo de selección (iteración 2)

Etapa (eliminatoria)	Criterio	Grupos que siguen
Universo	pares, tercias y cuartetos de 8 tickers	154
2. Correlación	media de correlaciones móviles (252 días) > 0.7	136 (18 fuera)
3. Engle–Granger	prioriza, no elimina (6 pares, regresión del grupo, bandera de regresión espuria)	136
4. Johansen (traza 95 %)	rechaza r = 0	28 (108 fuera)
6. Vector operable	ADF del spread p < 0.05 y vida media en [5, 60] días	**19** (9 fuera)
7. Estabilidad	Johansen en cada mitad de train y móvil: se reporta, no elimina	19

Entre los 19, la regla de la iteración 1 (máxima razón traza / crítico) elegiría KGC-B (1.33); GLD-GDX-B es el 4.º (1.20). La tabla completa, con la etapa y el motivo de descarte de cada grupo, está en `artifacts/selection_table.csv`.

3. Johansen: rango, vector, ADF y vida media

Todas las series son I(1) (ADF en niveles p = 0.69 / 0.19 / 0.20, en diferencias p ≈ 0). Johansen con constante sin restringir (`det_order = 0`), k_ar_diff = 1 elegido por BIC, 2 237 observaciones de train:

H_0	Traza	Crítico 95 %	Máx. eigenvalor	Crítico 95 %	Decisión
r = 0	35.82	29.80	27.54	21.13	rechaza (traza también al 99 %: 35.46)
r ≤ 1	8.28	15.49	7.19	14.26	no rechaza
r ≤ 2	1.09	3.84	1.09	3.84	no rechaza

Rango 1 por traza y por máximo eigenvalor (eigenvalores 0.0122, 0.0032 y 0.0005): solo el primer vector es estacionario, así que no hay otro con qué competir. **Normalización** sobre la pata de mayor |peso| (GDX = +1):

> ECT_t = ln GDX_t – 0.827 ln GLD_t – 0.448 ln B_t – c, con c = –2.066 (media en train).

Convención de signo: largo el spread = comprar los activos con $\tilde{\beta} > 0$ (GDX) y vender los de $\tilde{\beta} < 0$ (GLD y B). ADF del spread p = 0.0009; vida media –ln 2 / λ = **29.1 días**. El Johansen móvil de 2 años (figura 4) rechaza r = 0 solo en 14 % de las ventanas de train: con ventanas cortas tiene poca potencia, y los pesos se mueven aun dentro de train. Ese es el argumento para el filtro 1.

Figura 1 — Precios ajustados del grupo GLD-GDX-B



Figura 1. Precios normalizados del grupo.

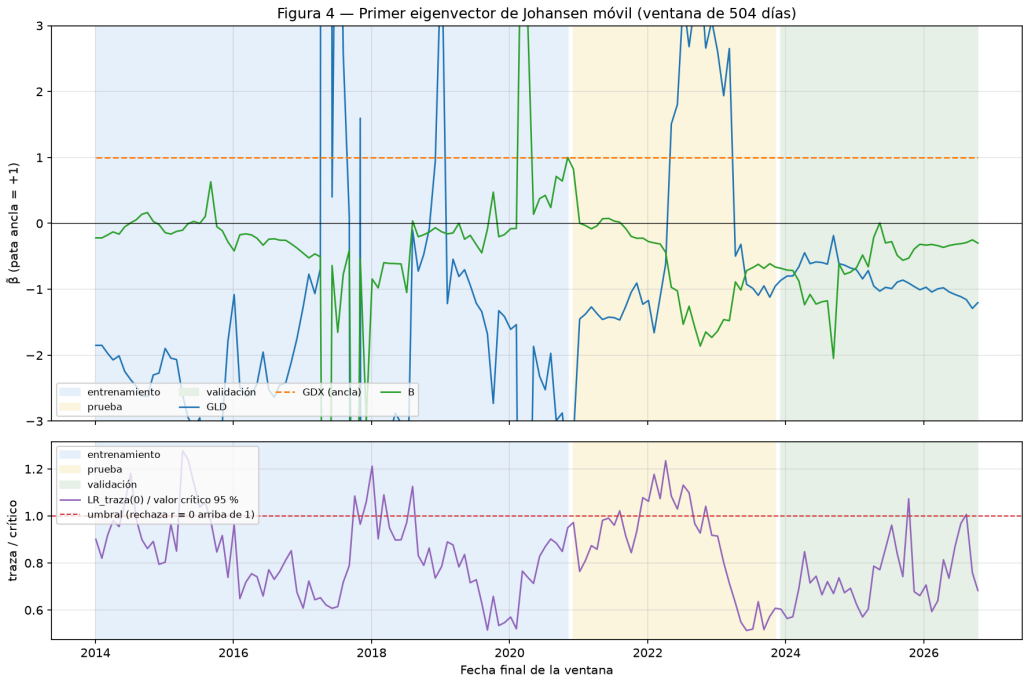


Figura 4. Primer eigenvector de Johansen móvil y razón traza / crítico.

4. Formulación como proceso de decisión secuencial (Powell)

La formulación completa (6 pasos y 5 elementos de cada filtro y del sistema) está en `docs/powell.md`. Resumen:

	Filtro 1 (pesos)	Filtro 2 (z-score)	Sistema completo
Estado	creencia (ĉ, β̂_GLD, β̂_B), P_t	creencia (μ̂, x̂), P_t	físico: acciones, efectivo, d_{t−1}, h_t, rearme · información: P_t, ECT_t, z_t · creencia: la de ambos filtros
Transición	caminata aleatoria, Q = q·I	μ caminata aleatoria, x AR(1) con ϕ	filtros + ejecución en t + 1 con costos
Observación	ln GDX_t = (1, −ln GLD_t, −ln B_t) z_t + v_t	ECT_t = μ_t + x_t + v_t	solo precios P_{t+1} (W_{t+1})
Política	regla de Kalman (PFA, θ = Q, R)	regla de Kalman (PFA, θ = ϕ, q_μ, q_x, r)	regla de bandas (PFA, θ = z_entrada, z_salida, z_stop, h_max) + sizing
Objetivo	error de predicción con deriva lenta	verosimilitud de innovaciones con media lenta	máx. Sharpe neto en train

Ganancia de Kalman. En el filtro 1, C_t K_t = 1 − R/S_t es la fracción de la sorpresa del día que se absorbe moviendo pesos: mediana 0.0038 en train (0.4 %). En el filtro 2 converge a K^μ ≈ 0.08 y K^x ≈ 0.74: casi toda sorpresa va a la desviación que revierte y muy poca a la media (figura 5).

5. Calibración: Q, R, inicialización, burn-in, normalización y signo

Filtro 1.

- $R = 3.31 \times 10^{-3}$, la varianza del residual de Johansen en train.
- $q = 1.6 \times 10^{-9}$ ($q/R \approx 4.8 \times 10^{-7}$) por **separación de escalas**: es el mayor q con el que el filtro absorbe a lo más 20 % de una desviación en 2 vidas medias (58 días).
- Por qué no máxima verosimilitud: elige un q mucho mayor, y entonces el ECT revierte por el filtro y no por los precios.

- $P_0 = 252 \cdot Q$. El estado arranca en el $\tilde{\beta}$ de Johansen. Burn-in de 252 días (2012).
- El ECT de t se calcula con los pesos **prior** $\hat{\beta}_{t|t-1}$: es la innovación del filtro y no está encogida por la actualización del día.

Filtro 2.

- $\phi = 0.969$ (vida media 22.1 días, AR(1)/OU del ECT en train).
- $q_x = 1.1 \times 10^{-4}$ y $r = 2.8 \times 10^{-5}$ por máxima verosimilitud.
- $q_\mu = 9.3 \times 10^{-7}$ por el mismo criterio de separación de escalas que el filtro 1.
- $\hat{\mu}_0 = \hat{x}_0 = 0$, $P_0 = \mathrm{diag}(q_x/(1-\phi^2))$; burn-in de 63 días.
- $z_t = (ECT_t - \hat{\mu}_{t|t-1}) / \hat{\sigma}_{t|t-1}$, con $\hat{\sigma}^2 = q_x/(1-\phi^2) + p^\wedge\mu + r$, todo **prior**.
- Prueba 4 en train: varianza de $v/\sqrt{S} = 0.995$ y Ljung–Box del rezago 1 con $p = 0.62$.

Normalización y signo: ancla GDX = +1 en Johansen, en el estado del filtro 1 (GDX no es estado: es la variable observada) y en el sizing ($N_i \propto |\hat{\beta}_i|$ con el signo de $\hat{\beta}_i$).

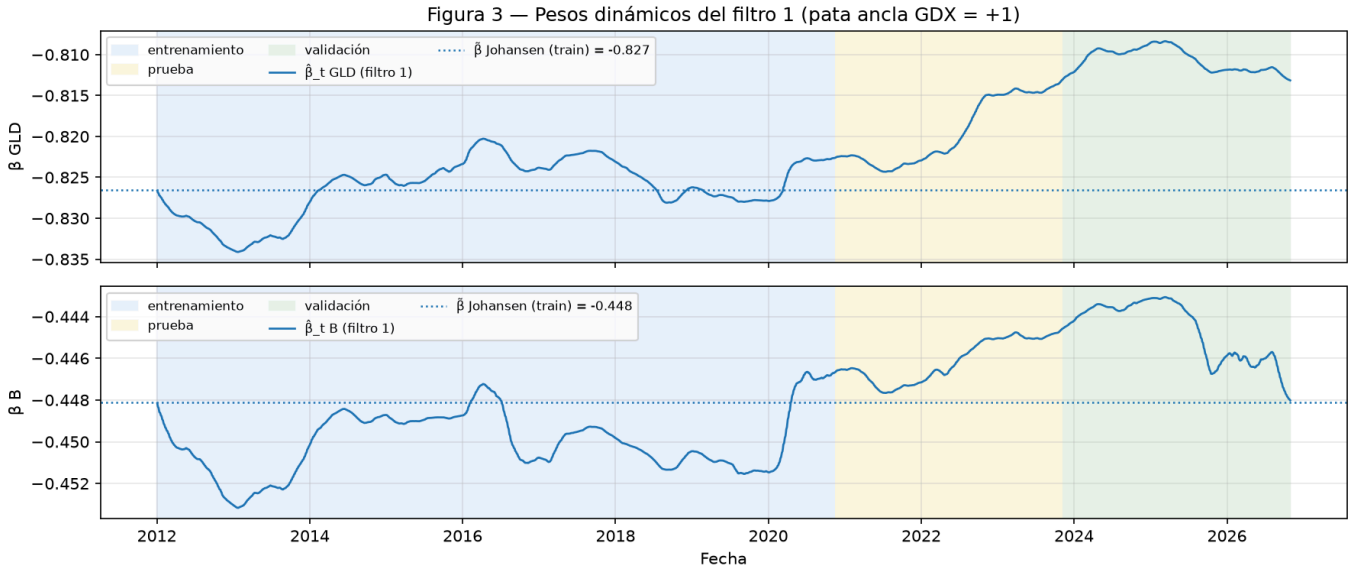


Figura 3. Pesos dinámicos $\hat{\beta}_t$ del filtro 1 contra el $\tilde{\beta}$ estático de Johansen.

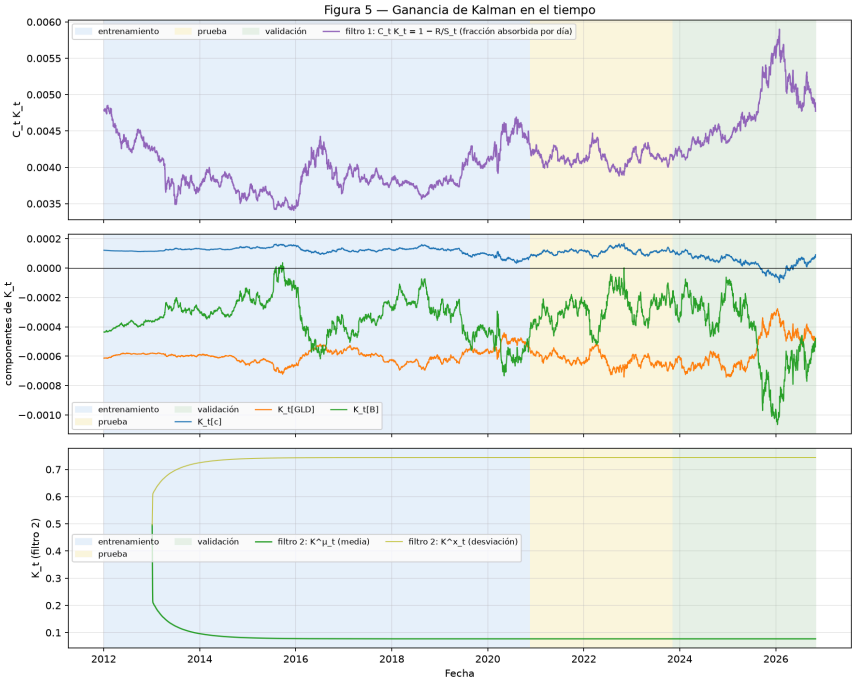


Figura 5. Ganancia de Kalman de ambos filtros.

6. VECM: α y su interpretación

VECM en train con constante sin restringir, rango 1 y k_ar_diff = 1; su β coincide con el de Johansen.

	GLD	GDX	B
α	−0.003	**−0.039**	**−0.034**
t	−0.9	−4.1	−3.4

$\beta^T\alpha = -0.021$ cumple $-2 < \beta^T\alpha < 0$ (la relación corrige), con vida media de 33.3 días. Solo GDX corrige: su contribución $\beta_{GDX}\cdot\alpha_{GDX} = -0.039$ cierra el spread, mientras que la de Barrick ($\beta_B\cdot\alpha_B = +0.015$) lo abre. Cuando el ETF de mineras se encarece frente al oro y a Barrick, es el ETF el que regresa; el oro casi no participa en el ajuste. Las tres vidas medias (Johansen 29.1, VECM 33.3, filtro 2 22.1 días) coinciden en orden de magnitud.

7. Umbrales y procedimiento de búsqueda

Regla (PFA).

- Plano: largo si $-z_{stop} < z_t < -z_{entrada}$; corto si $z_{entrada} < z_t < z_{stop}$.
- Con posición, cierra con esta prioridad: stop ($|z_t| \geq z_{stop}$) > holding ($h_t \geq h_{max}$) > salida direccional.
- Tras un stop o un holding, esa dirección se rearma solo cuando $|z_t| < z_{entrada}$.
- Se ejecuta al cierre de $t + 1$ con $N_i = 0.8\, V_t\, |\hat{\beta}_i| / \Sigma|\hat{\beta}_j|$.

Búsqueda. El grid se registró en `docs/decisiones.md` antes de ver resultados:

- $z_{entrada} \in \{1, 1.25, 1.5, 1.75, 2, 2.5\}$, $z_{salida} \in \{0, 0.25, 0.5\}$, $z_{stop} \in \{2.5, 3, 3.5, 4\}$ y $h_{max} = k \cdot 29$ días con $k \in \{1, 2, 3\}$.
- Hay 207 combinaciones válidas ($z_{salida} < z_{entrada} < z_{stop}$); 135 tienen al menos 10 operaciones.
- Objetivo: Sharpe neto anualizado en train, con la simulación completa y los costos.
- Resultado: **θ = (1.0, 0.0, 2.5, 87 días)**, con Sharpe 0.66 y 24 operaciones en train.
- El 83 % de las combinaciones tiene Sharpe positivo en train, y las 5 mejores comparten $z_{entrada} = 1$ y $z_{salida} = 0$.
- Limitación: el óptimo está en el borde de la rejilla, que no se amplió, y el Sharpe deflactado del grid en train es 0.59.
- Fuera de muestra, ese θ es el 13.º de 135 en prueba y el 1.º en validación. La correlación de Spearman entre el Sharpe de train y el de fuera de muestra es 0.49 (prueba) y 0.43 (validación).

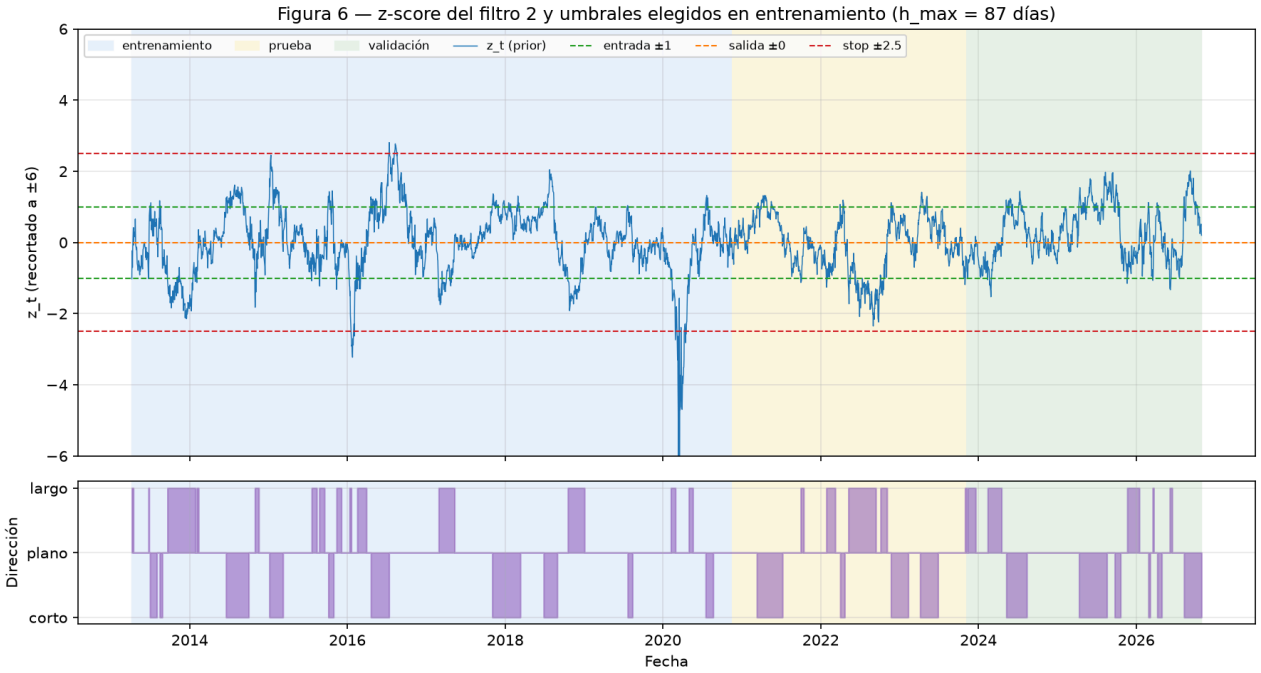
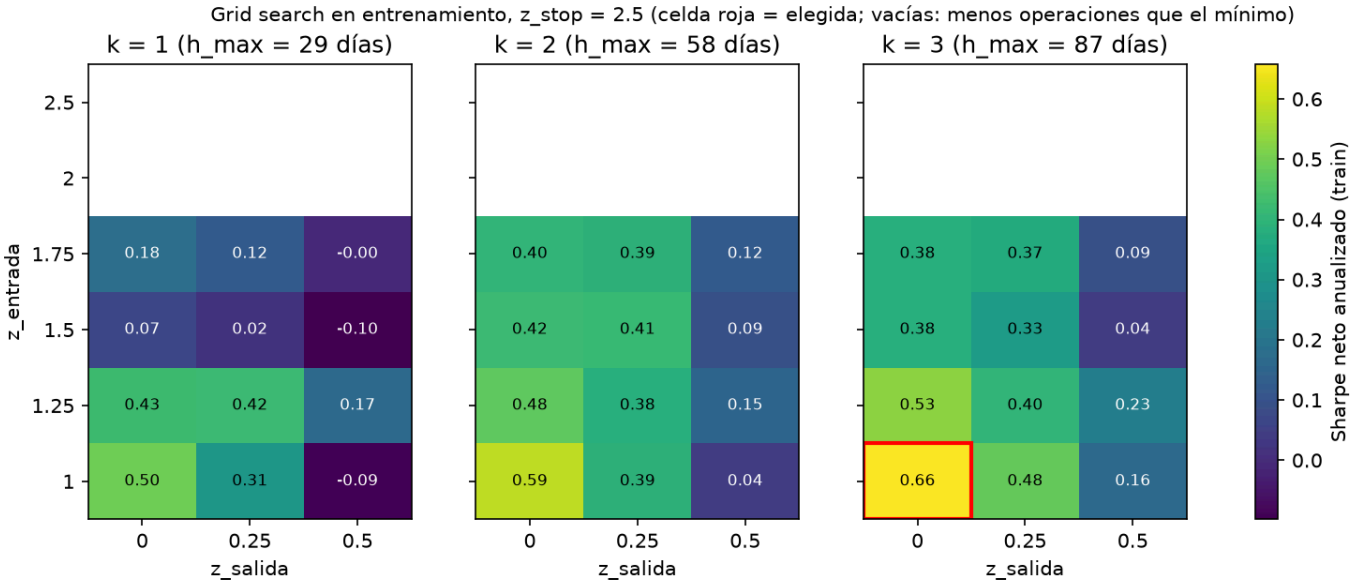


Figura 6. z-score prior con los umbrales elegidos.



Superficie del grid search en train.

8. Resultados por partición, costos y rebalanceo

Métrica	Entrenamiento	Prueba	Validación	Total (encadenado)
Periodo	2013-04 → 2020-11	2020-11 → 2023-11	2023-11 → 2026-10	2013-04 → 2026-10
Rendimiento neto	+20.5 %	+8.1 %	+11.2 %	+44.8 %
CAGR	2.5 %	2.7 %	3.7 %	2.8 %
Sharpe neto	0.66	0.74	1.01	0.75
Sortino	1.01	1.12	1.61	1.16
Calmar	0.38	0.59	0.98	0.42
Max drawdown (días)	−6.6 % (1 185)	−4.5 % (244)	−3.7 % (171)	−6.6 % (1 185)
Operaciones / ganadoras	24 / 79 %	9 / 89 %	11 / 91 %	44 / 84 %
Profit factor	2.49	4.55	8.11	3.26

Cada partición arranca con $1,000,000 y el CAGR es bajo porque solo 80 % del capital está invertido y la estrategia está en el mercado menos de la mitad de los días. En las tres particiones suman $522,687 de P&L bruto, $118,744 de comisiones y $6,067 de préstamo, para $397,876 netos: los costos son el 24 % del bruto. Por año, 13 de 14 años son positivos; el único negativo es 2016 (−5.3 %).

Rebalanceo diario contra banda de no-rebalanceo (θ fijo; la política oficial es el diario, con el que se eligió θ):

Banda	Sharpe train	Sharpe prueba	Sharpe validación	Rebalanceos train	Comisiones train
diario (0)	0.66	0.74	1.01	697	$66,527
5 %	0.69	0.72	0.99	146	$59,671
10 %	0.66	0.83	1.07	45	$56,077
20 %	0.66	0.82	1.12	9	$54,579

En train la banda casi no cambia el Sharpe, pero ahorra hasta 18 % de comisiones. Elegir la banda de 20 % por lo que pasa en prueba y validación sería ajustar con esos datos, así que se reporta como escenario.

Estático contra dinámico (mismo θ): con el ECT estático de Johansen el Sharpe es 0.72 / 0.20 / 1.31; con el dinámico, 0.66 / 0.74 / 1.01. El estático se cae en prueba, donde su ECT deja de ser estacionario (ADF p = 0.27). El dinámico es más consistente entre particiones porque absorbe la deriva de nivel de la relación.

Figura 2 — Spread del portafolio (ECT dinámico) con las operaciones

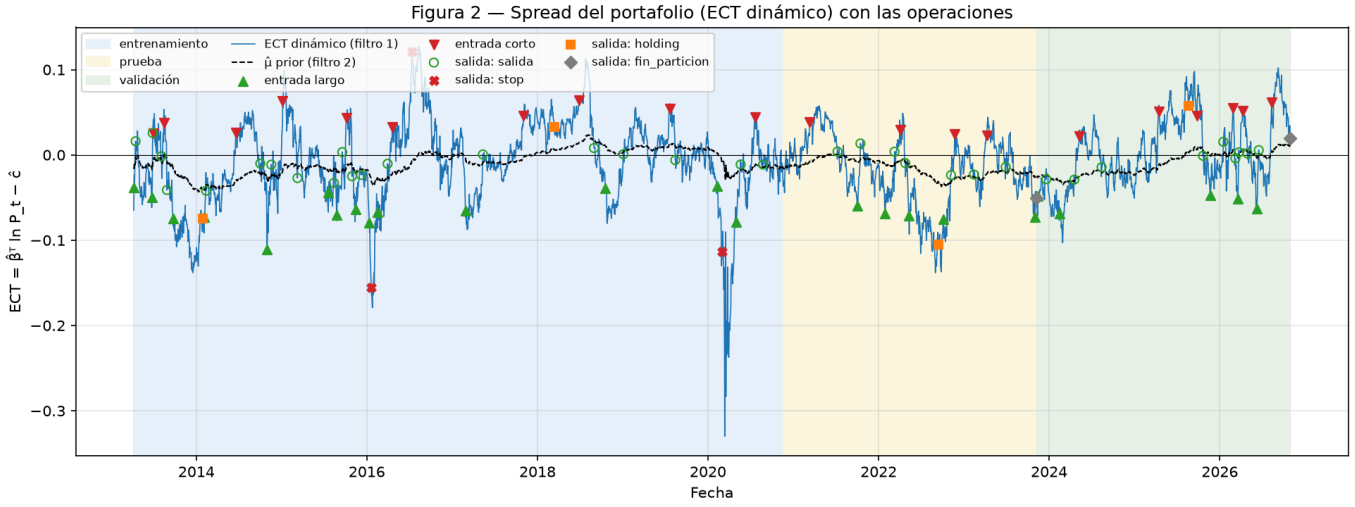


Figura 2. Spread con las señales de entrada y salida.

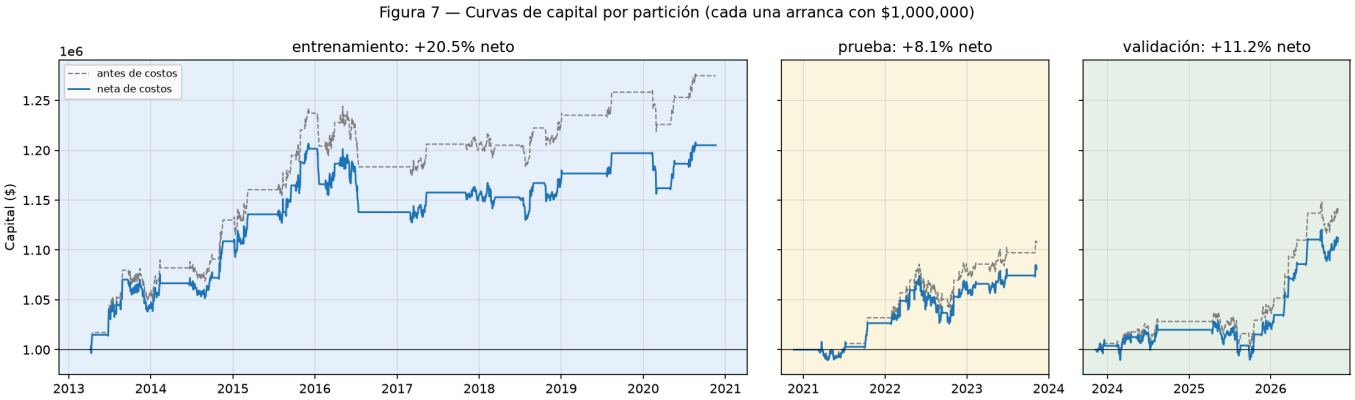


Figura 7. Curvas de capital por partición.

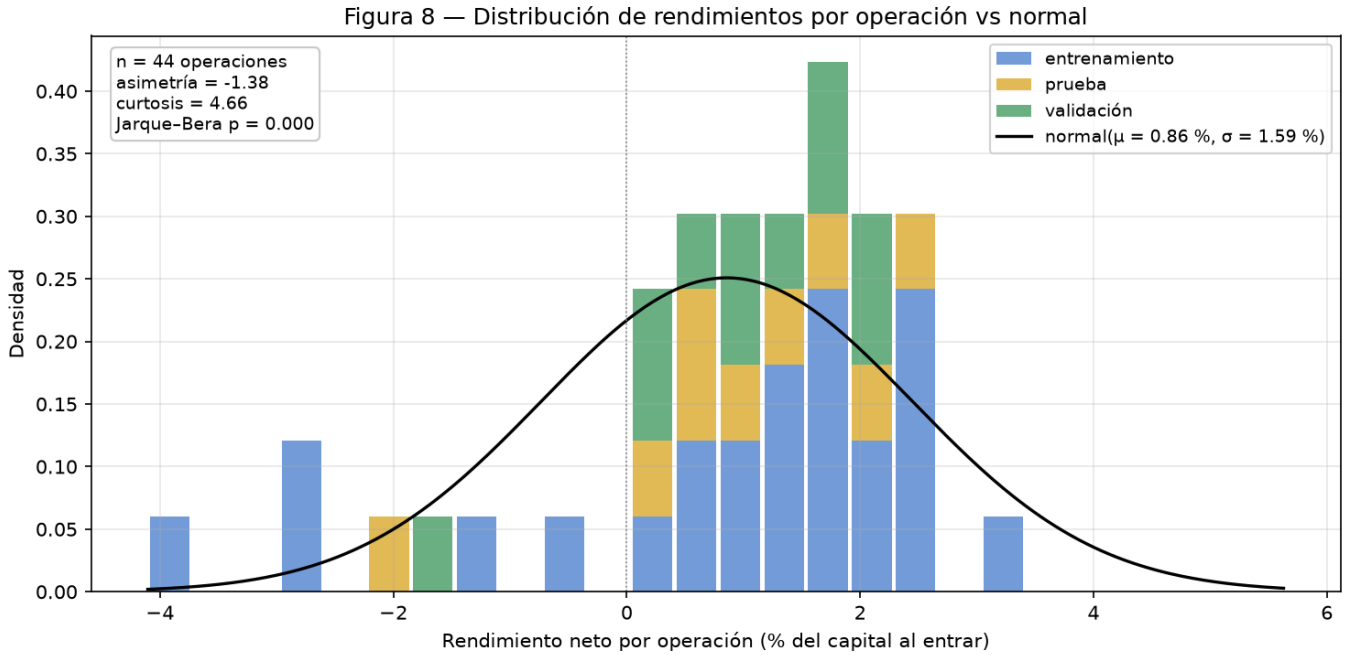
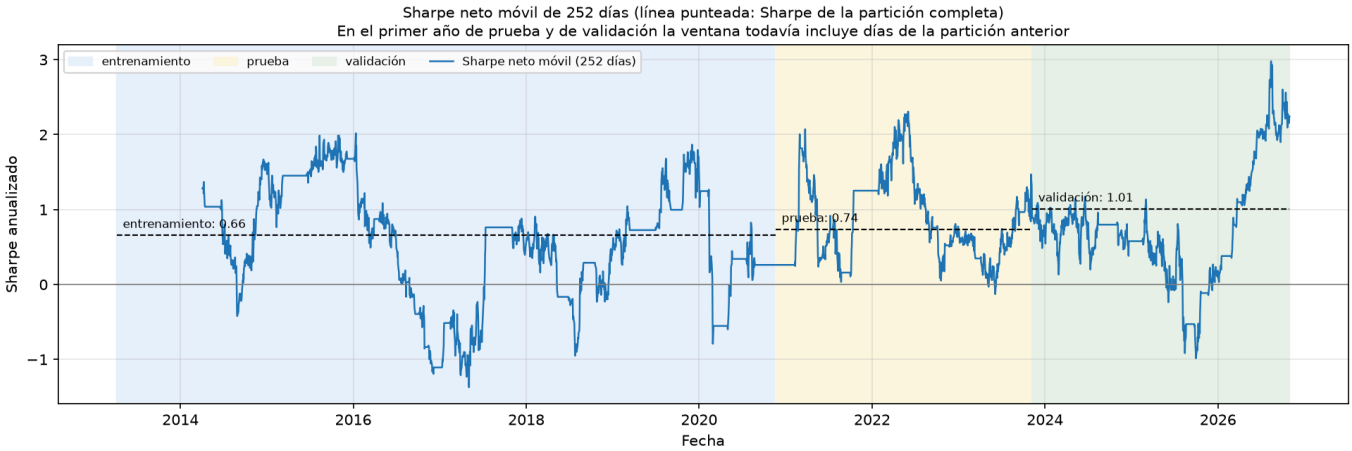
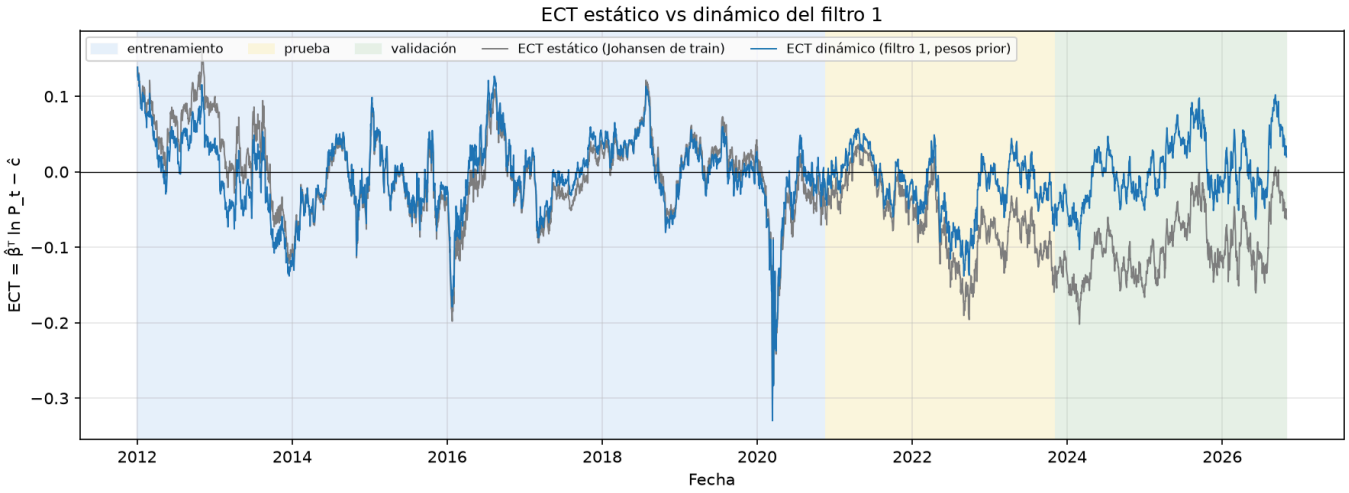


Figura 8. Distribución de rendimientos por operación con la normal superpuesta.

La distribución por operación tiene sesgo −1.38 y curtosis 4.66 (Jarque–Bera $p = 7.6 \times 10^{-5}$): muchas ganancias pequeñas por reversión y pocas pérdidas grandes por stop y holding. Ninguna operación cerrada por reversión perdió.



Sharpe neto móvil de 252 días.



ECT estático contra dinámico.

9. ¿Relación estructural o artefacto?

Argumentos a favor de una relación estructural.

1. **Mecanismo económico directo:** GDX es una canasta de mineras de oro y Barrick está entre sus mayores posiciones; las tres series dependen del precio del oro.
2. **El VECM confirma la corrección de error** ($\beta^T\alpha = -0.021$), con el ajuste en el activo esperado (GDX).
3. **Fuera de muestra la relación se debilita pero no se rompe.** El ECT estático se desplaza en promedio 1.2 / 1.9 desviaciones de train en prueba / validación, contra ≈ 10 del grupo de la iteración 1. El dinámico se mantiene centrado (media −0.02 / +0.003; ADF p = 0.055 / 0.011).
4. **La estrategia gana en todos los años fuera de muestra.** Tiene 18 de 20 operaciones ganadoras y +$122 mil aun sin sus 3 mejores operaciones. No toca el stop fuera de muestra.

Argumentos a favor de que parte del resultado es artefacto.

1. **Pruebas múltiples:** 30 de 154 grupos rechazan r = 0 cuando se esperaban 7.7 por azar, y solo 4 rechazan al 99 % (Bonferroni exigiría $\alpha = 0.00032$).
2. **Sesgo de selección:** la tercia se eligió en una segunda iteración, con lo aprendido de prueba y validación. Con el mismo pipeline, los 19 sobrevivientes tienen una mediana de Sharpe fuera de muestra de 0.21. GLD-GDX-B es el 1.º de 19, y la correlación entre el Sharpe de train y el de fuera de muestra a través de los grupos es −0.29. El **Sharpe deflactado** (N = 19) es ≈ 0.46.
3. **Inestabilidad:** el Johansen móvil rechaza poco (14 % de las ventanas de train), y en la prueba anidada (train partido 60/20/20) esta familia de grupos da Sharpe negativo en 2017–2020.
4. **Sensibilidad:** con tolerancias de los filtros de 10 % o 40 % en lugar de 20 %, el Sharpe fuera de muestra baja a 0.17–0.69 contra 0.87. Los hiperparámetros de la optimización, en cambio, son robustos.

Conclusión. La relación GLD-GDX-B es **estructural en su origen pero inestable en sus pesos**: existe un vector que corrige, con fundamento económico, cuyo nivel y pesos derivan con los años. La estrategia funciona porque el filtro 1 sigue esa deriva. Que este grupo en particular sea el mejor y que el Sharpe fuera de muestra sea ≈ 0.9 no es estadísticamente concluyente después de corregir por la búsqueda. En operación real se usaría con la regla de monitoreo y apagado del post-mortem (`project_management/postmortem.md`).

10. Supuestos y limitaciones

- **Supuestos de mercado:**
  - Se opera al precio de cierre de t + 1 sin slippage ni impacto.
  - Comisión de 0.125 % por pata y préstamo de 0.25 % anual sobre el nocional corto, siempre disponible.

    - El efectivo no rinde intereses ($r_f = 0$).
- **Datos:**
    - Precios ajustados de Yahoo.
    - Sesgo de supervivencia: solo se excluyen empresas adquiridas.
    - Universos elegidos por el equipo.
- **Modelo:**
    - Johansen supone una sola relación lineal en log-precios con constante.
    - Los filtros suponen ruido gaussiano.
    - Q, R, ϕ y θ están congelados desde train; no hay recalibración, porque la recalibración probada no mejoró fuera de muestra de forma consistente.
    - Fuera de muestra la varianza de las innovaciones del filtro 2 baja a 0.51 / 0.58: el filtro sobreestima el ruido y es conservador.
- **Estadística:**
    - Hay pocas operaciones (9 y 11 fuera de muestra), así que el Sharpe tiene mucho error.
    - Ljung–Box a 5–10 rezagos rechaza con cualquier modelo del filtro 2.
    - El grid tiene su óptimo en el borde.
- **Proceso:** dos iteraciones de selección. La segunda la autorizó el profesor y está documentada completa en `docs/decisiones.md`, incluidas las pruebas que no funcionaron (prueba anidada, hiperparámetros, recalibración y un solo sector).
- **Excluido del alcance:** Risk Parity entre grupos (sección 3.7), operación en vivo y datos intradía.